

VERİ SETİ KARAKTERİSTİĞİ VE KEŞİFSEL VERİ ANALİZİ (EDA)

Giriş

Projemizin temel amacı, geri dönüşüm tesislerindeki konveyör bantları üzerinde akan atıkları yapay zeka ile otomatik olarak ayırt edebilmek. Bu doğrultuda, endüstriyel standartlarda hazırlanmış olan **WaRP (Waste Recycling Plant)** veri setini kullandık. Bu veri seti, gerçek bir fabrikada hattan geçen plastik şişelerden kartonlara, camlardan deterjan kutularına kadar tam **28 farklı atık kategorisini** barındırıyor.


Yapay zeka modelimizi eğitmeye başlamadan önce, elimizdeki ham malzemenin röntgenini çekmek ve bizi ne tür zorlukların beklediğini anlamak adına Ultralytics Platformu üzerinde detaylı bir **Keşifsel Veri Analizi (EDA)** gerçekleştirdik. Elde ettiğimiz veriler, sistemin başarısını doğrudan etkileyecek çok kritik yapısal özellikleri önümüze serdi:

Veri Seti(Database) Hakkında

Veri Dağılımı

Veri setimizde toplam **13.685 adet görsel** bulunuyor. Bu görselleri modelin eğitimi, denetlenmesi ve nihai testi için şu şekilde üç farklı havuzda paylaştık:

- Training (Eğitim Seti):** Verinin %67.9'unu oluşturuyor. Modelin atıkları öğrenirken bizzat çalışacağı ana mutfak burası.
- Validation (Doğrulama Seti):** %17.0'lık bir paya sahip. Model eğitilirken "acaba doğru mu öğreniyor yoksa ezberliyor mu?" diye kendisini check ettiğimiz ara kontrol mekanizması.
- Test Seti:** %15.1'lik kısmı kapsıyor. Model bittikten sonra başarı puanını ölçeceğimiz, yapay zekanın daha önce hiç görmediği "kör test" alanı.




Analiz sonuçlarında bir veriyle karşılaştık: Elimizdeki veri setinin **yalnızca %21.7'si etiketlenmiş nesne barındırıyor**. Geriye kalan yaklaşık %78.3'lük kısım ise üzerinde hiçbir çöp olmayan, tamamen boş akan konveyör bandı resimlerinden oluşuyor. YOLO gibi nesne tespit modelleri için bu durum iki ucu keskin bir bıçak gibidir. Bir yandan modelin boş bandı "çöp" sanmasını engeller (yani yanlış alarmları düşürür), diğer yandan ise yapay zekanın öğrenme sürecini ve işlem süresini ciddi şekilde uzatır.

Sınıf Dağılımı

Veri setindeki resimlerin üzerinde tam **10.374 adet çöpün konumu (bounding box)** tek tek işaretlenmiş. Platformun bize sunduğu *Class Distribution* ve *Top Classes* grafiklerine baktığımızda, endüstriyel projelerin en büyük kabusu olan "Sınıf Dengesizliği" ile karşı karşıya olduğumuzu gördük:


- Veri setindeki tüm etiketlerin tek başına **%16.1'ini (1.666 adet) sadece class4 oluşturuyor**.
- `class4`, `class1`, `class0`, `class2` ve `class17` gibi ilk 5 popüler sınıf, veri setinin neredeyse tamamını domine ediyor.
- Grafiğin en sağına, yani azınlık sınıflara doğru gittiğimizde (örneğin `class21`), etiket sayılarının yok denecek kadar azaldığını, sadece birkaç on adetle sınırlı kaldığını gördük.



Eğer modeli bu haliyle dümdüz eğitirsek, yapay zeka `class4` atığını nerede görse şak diye tanıyacak; ama iş nadir geçen `class21` atığına geldiğinde onu ya tamamen görmezden gelecek ya da popüler sınıflardan birine benzetecektir. Bu problemi çözmek için kesinlikle eğitimi manipüle etmemiz ve özel veri artırma yöntemleri kullanmamız gerektiğini bu analiz sayesinde anladık.

Resim Boyutları ve Düzeni

- **Görüntü Çözünürlükleri:** Resimlerin boyut dağılımı ortalama **480 X 330 piksel** civarında yoğunlaşıyor. Yani elimizde devasa çözünürlükte fotoğraflar yok, orta-düşük kalitede endüstriyel kamera görüntüleri var. Bu bizim için iyi bir şey; eğitim yaparken modeli boşuna yüksek çözünürlüklerle (`imgsz=1280` gibi) yorup ekran kartını kilitlememize gerek yok, standart 640 boyutu fazlasıyla yeterli olacaktır.
- **Kutuların Boyutları:** Atıkların resim içindeki kapladığı alan ortalama **186 X 180 piksel**. Çerçeve boyutunun 480 X 330 olduğunu düşünürsek, çöpler resmin içinde çok küçük noktalar halinde kalmıyor; resmin kayda değer bir kısmını kaplıyorlar. Bu sayede modelin "küçük nesneleri yakalayamama" gibi kronik bir problemle boğuşmayacağını öngördük.




- **Kare Başına Düşen Çöp Sayısı:** Grafik bize çok net bir şey söylüyor: Resimlerin neredeyse tamamında **yalnızca 1 adet atık nesnesi** var. Birden fazla nesnenin aynı kareye denk geldiği durumlar yok denecek kadar az. Bu veri, fabrikadaki sistemin temiz çalıştığını, çöplerin üst üste yığılmadığını, tane tane aktığını gösteriyor. Dolayısıyla nesnelerin birbirini kapatması (occlusion) yüzünden modelin kafasının karışma ihtimali oldukça düşük.

Model Eğitimi Sonrası Veri Analizi

Veri setimizin endüstriyel yapısını ve zorluklarını analiz ettikten sonra, projemizin ilk aşaması için hız ve performans dengesiyle bilinen **YOLOv8n (Nano)** modelini tercih ettik. Amacımız, donanımı fazla yormadan 100 epoch'luk bir eğitimle sistemin nasıl bir tepki vereceğini görmek ve bir temel çizgi (baseline) oluşturmaktır.

Ancak eğitim bittiğinde karşımıza çıkan grafikler ve performans metrikleri, bize bu veri setinin öyle kolay lokma olmadığını ve modelimizin ciddi yapısal tıkanıklıklar yaşadığını gösterdi. Şimdi bu sonuçları ve arkasında yatan nedenleri açık yüreklilikle masaya yatıralım:

Başarı Metrikleri Analizi



Ultralytics platformunun eğitim sonu raporunda karşımıza çıkan nihai başarı tablomuz şu şekilde gerçekleşti:

- **Precision (Keskinlik - %23.4):** Modelimizin yaptığı her 4 tahminden sadece 1 tanesi doğru çıktı. Yani model sıklıkla boş bandı veya yanlış bir nesneyi atık sanıp hatalı kutu çiziyor.
- **Recall (Duyarlılık - %23.0):** Model banttan geçen gerçek atıkların sadece %23'ünü fark edebildi, geriye kalan %77'lik atık yükünü hiç görmeden ıskaladı.
- **mAP50 (%16.5) & mAP50-95 (%11.5):** Modelin genel başarı puanını gösteren mAP50 değerimiz %16.5'te kaldı. Kutuların nesneyi tam ortalamasını ölçen o katı metrik (mAP50-95) ise %11.5 seviyesinde.

Bu değerler bize net bir şey söylüyor; şu anki haliyle bu modeli fabrikadaki gerçek bir robotik kola bağlarsak robot bandı birbirine katar, çöplerin çoğunu ıskalar ve yanlış kutulara hamle yapar. Peki neden böyle oldu? Cevabı kayıp (loss) grafiklerinde gizli.

Loss Grafikleri ve Overfitting(Aşırı Öğrenme) Analizi




Eğitim esnasında modelin yaptığı hataları gösteren `box_loss` (kutu konumu kaybı) ve `cls_loss` (sınıflandırma kaybı) grafiklerini incelediğimizde çok net bir mühendislik problemi teşhis ettik:

- Grafikteki düz çizgiler (Training Loss), 100 epoch boyunca istikrarlı bir şekilde aşağı doğru düşüyor ve sıfıra yaklaşıyor. Yani model, eğitim setindeki resimleri mükemmel bir şekilde öğreniyor.
- Ancak kesikli çizgilere (Validation Loss) baktığımızda işler değişiyor. Doğrulama kaybı belirli bir epoch'tan sonra düşmeyi tamamen bırakıyor ve yukarıda, yüksek bir seviyede sabit kalıyor. Eğitim kaybı ile doğrulama kaybı arasındaki bu devasa makas, yapay zeka dünyasında **Overfitting (Aşırı Öğrenme / Ezberleme)** olarak adlandırılır.

Modelimiz, eğitim setindeki çöp resimlerini o kadar çok gördü ki bir süre sonra onları **ezberlemeye** başladı. eğitim setinde kusursuz sonuçlar verirken, doğrulama (validation) setinde daha önce hiç görmediği yeni ve farklı açılardan gelen bir atık resmiyle karşılaşınca tamamen çuvalladı. Genelleme yeteneği kazanamadı.


Karmaşıklık Matrisinin Analizi



- Matrisin üzerinde sadece belirli sınıflarda (class1, class2, class16, class17, class18, class23) parlak kareler (doğru tahminler) var.
- Matrisin neredeyse %80'ini oluşturan diğer 20'ye yakın sınıf ise tamamen karanlık kalmış durumda.

Veri setinde etiket sayısı çok az olan o nadir sınıfları öğrenmek için hiç uğraşmamış, onları tamamen "arka plan" (background) olarak görmeyi tercih etmiş. Sadece elinde bolca veri bulunan popüler sınıflara odaklanmış. Bu da bize veri setindeki dengesizliği çözmeden model mimarisini ne kadar değiştirirsek değiştirelim başarıya ulaşamayacağımızı kanıtlıyor.

Doğrulama Eğrilerinin Analizi



F1-Confidence eğrisine baktığımızda, modelin ulaştığı en yüksek F1 puanının (yani doğruluk ve duyarlılık dengesinin) sadece **0.21** seviyesinde kaldığını görüyoruz. Üstelik bu tepe noktasına Confidence = 0.08 gibi çok düşük, yani modelin kendine neredeyse hiç güvenmediği bir eşik değerinde ulaşıyoruz. Güven eşikini (Confidence threshold) gerçekçi bir oran olan %50'lere çıkardığımızda ise modelin başarı eğrisi adeta çakılıyor.

Peki Bu Düşük Doğruluk İçin Ne Yapabiliriz?

İlk eğitimimizin %16.5 mAP ile sonuçlanması projemizin başarısız olduğu anlamına gelmiyor; aksine bize bir sonraki aşamada ne yapmamız gerektiğine dair çok net bir yol haritası sunuyor. Bu sistemi fabrikada çalışabilecek endüstriyel olgunluğa getirmek için bir sonraki iterasyonda şu somut adımları uygulayacağız:

- 1. Nano Modelden Small/Medium Modeline Geçiş:** Eğitmekte olduğumuz 28 farklı atık sınıfı, karmaşık endüstriyel şekil varyasyonlarına sahip. YOLOv8n (Nano) modeli, parametre sayısı az olduğu için bu kadar çok varyasyonu sırtlayamadı ve kapasitesi yetersiz kaldı. Bir sonraki eğitimde kesinlikle **YOLOv11-Small (s)** veya **Medium (m)** mimarisine geçerek modelin öğrenme kapasitesini artıracacağız.
- 2. Ezberlemeyi (Overfitting) Kırmak İçin Agresif Veri Artırma:** Modelin resimleri ezberlemesini engellemek için Ultralytics eğitim parametrelerindeki veri artırma (augmentation) ayarlarını sonuna kadar açacağız. `mosaic=1.0` ve `mixup=0.3`

kullanarak resimleri birbirine karıştırarak, `degrees=15.0` ile çöpleri rastgele döndürerek yapay zekaya her epoch'ta bambaşka bir dünya sunacağız. Böylece ezber yapmasının önüne geçeceğiz.